ITM

Análisis de datos

2da evaluación 20%

Sebastian Rivera

Sebastian Espinosa Hernández

Maria Alejandra Rua Monsalve

Sofía Ortiz Serna

Fase 1: Exploración de bases de datos.

A continuación se indican las tres bases de datos elegidas por el equipo con su respectiva descripción.

Job Salary Prediction Dataset

https://www.kaggle.com/datasets/nalisha/job-salary-prediction-dataset

Fuente y tipo de datos

- Fuente: Kaggle.
- Tipo: Secundaria
- Formato: Tabular (CSV).

Características básicas

- Registros: 250,000 registros.
- Atributos principales.
    - Título del trabajo
    - Nivel de experiencia
    - Educación
    - Habilidades
    - Industria
    - Ubicación
    - Tamaño de la empresa
    - Salario (variable objetivo)

- Tipo de variables: Categóricas y numéricas.

Nivel de documentación y aplicaciones

- Documentación: Media.
- Según Kaggle, su usabilidad tiene una puntuación de 10.00 indicando que es completa, tiene buena credibilidad y compatibilidad.

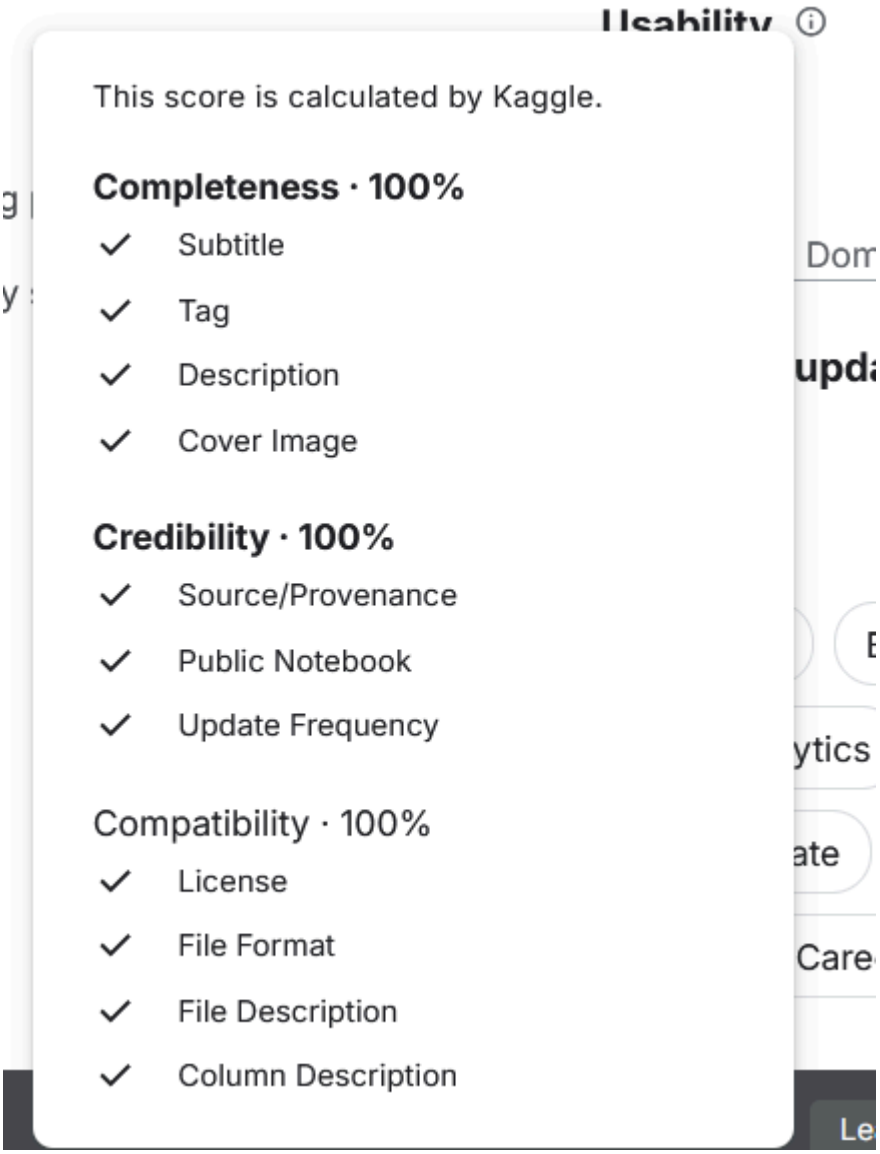

- Aplicaciones:
  - Modelos de predicción salarial (regresión)
  - Análisis del mercado laboral
  - Recursos humanos (benchmark salarial)
  - Sistemas de recomendación de empleos

Student Dropout Prediction Dataset

https://www.kaggle.com/datasets/meharshanali/student-dropout-prediction-dataset

Fuente y tipo de datos

- Fuente: Kaggle.
- Tipo: Secundaria.
- Formato: Tabular (CSV).

Características básicas

- Registros: 10,000 estudiantes
- Atributos: 19 columnas
- Variables incluyen:
    - Datos demográficos
    - Información académica
    - Comportamiento del estudiante
    - Variable objetivo: abandono (dropout)
- Tipos: Numéricos y categóricos
- Presenta 5% - 5.1% de valores faltantes

Nivel de documentación y aplicaciones

- Documentación: Buena (incluye descripción de variables y contexto del problema). Según Kaggle, su usabilidad tiene una puntuación de 10.00 indicando que es completa, tiene buena credibilidad y compatibilidad.

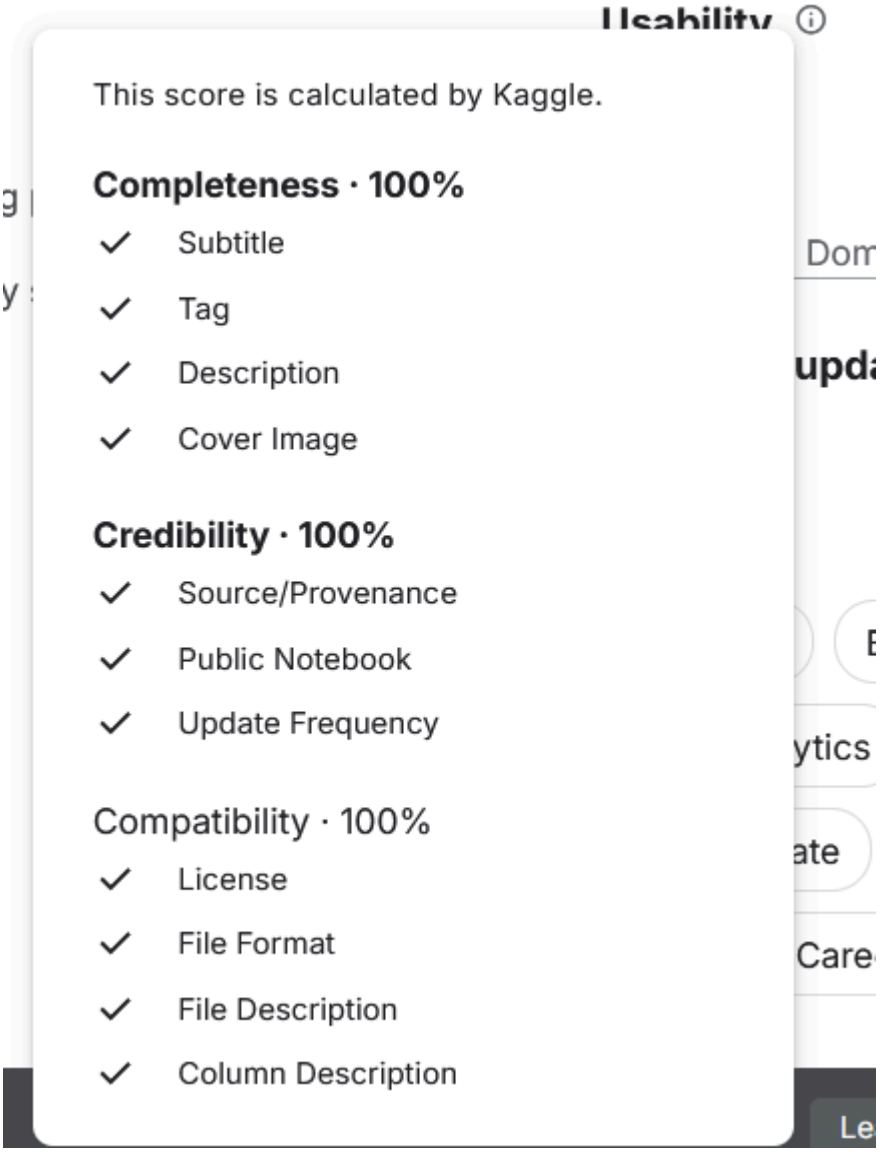

- Aplicaciones:

- Clasificación (abandona / no abandona)
- Sistemas de alerta temprana en educación
- Analítica educativa
- Políticas de retención estudiantil

Student Engagement Dataset

https://www.kaggle.com/datasets/joyee19/studentengagement

Fuente y tipo de datos

- Fuente: Kaggle (captura de imágenes de estudiantes).
- Tipo: Secundaria.
- Formato: Imágenes (no tabular).

Características básicas

- Datos: Imágenes capturadas desde cámaras (laptops).
- Contenido:
  - Rostros de estudiantes
  - Expresiones faciales
  - Posturas o atención
- Se usa para detectar niveles de engagement en clases online
- Tipo: Datos no estructurados (visión por computador).

Nivel de documentación y aplicaciones

- Documentación: Media- baja, su usabilidad según Kaggle es de 4.38

Usability

4.38

This score is calculated by Kaggle.

Completeness · 75%

- ✓ Subtitle
- ✓ Tag
- ✓ Description
- ✗ Cover Image

Credibility · 33%

- ✗ Source/Provenance
- ✓ Public Notebook
- ✗ Update Frequency

Compatibility · 0%

- ✗ License
- ✗ File Format
- ✗ File Description

- Aplicaciones:
  - Computer Vision
  - Reconocimiento facial

- Clasificación de atención (engaged vs not engaged)
- Educación virtual (e-learning analytics)

Base de datos seleccionada

El equipo seleccionó la base de datos Job Salary Prediction Dataset por su alta relevancia en el análisis del mercado laboral y su aplicabilidad en problemas reales, permitiendo estudiar cómo variables como experiencia, educación, habilidades y ubicación influyen en los salarios. Además, al ser un conjunto de datos estructurado en formato tabular, facilita su procesamiento y el desarrollo de modelos predictivos sin requerir herramientas complejas. También presenta un equilibrio adecuado entre complejidad y manejabilidad, lo que permite realizar análisis significativos sin una sobrecarga técnica, y cuenta con una documentación suficiente que favorece la correcta interpretación de los datos. En conjunto, estos aspectos la convierten en una opción pertinente, práctica y alineada con los objetivos del equipo.