Taller 3: Proyecto Integral de Business Intelligence (BI)

Dataset Students Performance in Exams

Análisis de datos

Sebastian Rivera Mira

Sebastian Espinosa Hernández

Maria Alejandra Rua Monsalve

Sofía Ortiz Serna

Instituto Tecnológico Metropolitano

Facultad de Ingenierías

Medellín – Antioquia

2026

Fase 1: Comprensión del problema

1. Descripción del contexto del dataset

Este dataset reúne información sobre el rendimiento académico de estudiantes en exámenes, a partir de sus puntajes en matemáticas, lectura y escritura. Además, incluye variables de contexto como el género, el grupo étnico, el nivel educativo de los padres, el tipo de almuerzo y si el estudiante realizó un curso de preparación para exámenes.

En general, este conjunto de datos permite analizar cómo estos factores pueden influir en los resultados académicos. A partir de esto, se pueden identificar patrones de desempeño, posibles diferencias entre grupos de estudiantes y obtener información útil para mejorar el acompañamiento educativo.

2. Identificación del problema de análisis o negocio

El objetivo principal del análisis es entender qué factores están más relacionados con el rendimiento académico de los estudiantes y si existen diferencias importantes entre distintos grupos.

No se trata solo de describir los puntajes, sino de identificar qué condiciones parecen favorecer o afectar el desempeño en matemáticas, lectura y escritura.

Si se piensa en la toma de decisiones, este análisis puede ser útil para que una institución educativa diseñe estrategias de apoyo más específicas. Por ejemplo, reforzar la preparación para exámenes, identificar estudiantes con mayor riesgo de bajo rendimiento o analizar si ciertas condiciones familiares y escolares están relacionadas con los resultados.

3. Formulación de preguntas clave

- ¿Existe relación entre haber realizado el curso de preparación para exámenes y obtener mejores puntajes en matemáticas, lectura y escritura?
  Esta pregunta surge porque el dataset incluye directamente esta variable junto con los puntajes.

- ¿Cómo varía el desempeño académico según el nivel educativo de los padres?
  Es relevante porque permite analizar la posible influencia del entorno familiar en el rendimiento.

- ¿Existen diferencias de rendimiento entre grupos según género, tipo de almuerzo o grupo étnico?
  Esta pregunta permite comparar distintos subgrupos y detectar posibles desigualdades.

Fase 2: Formulación de hipótesis

En esta fase se plantearon dos hipótesis principales para analizar factores que podrían estar relacionados con el rendimiento académico.

La primera hipótesis busca evaluar si completar un curso de preparación para exámenes influye en el puntaje promedio de los estudiantes. Para esto, se definió como hipótesis nula que no existen diferencias entre quienes realizaron el curso y quienes no, y como hipótesis alternativa que sí existen diferencias.

Se aplicó una prueba t para muestras independientes, junto con la prueba de Mann-Whitney U como apoyo. En ambos casos, el p-valor fue menor a 0.05, por lo que se rechaza la hipótesis nula. Esto sugiere que el curso de preparación está asociado con mejores resultados académicos.

La segunda hipótesis analiza si el nivel educativo de los padres está relacionado con el desempeño académico. La hipótesis nula plantea que no hay diferencias entre los grupos, mientras que la alternativa indica que sí las hay.

Para este caso se utilizó un ANOVA de una vía, acompañado de la prueba de Kruskal-Wallis. Los resultados mostraron un p-valor menor a 0.05, por lo que también se rechaza la hipótesis nula. En consecuencia, se concluye que el nivel educativo de los padres sí está relacionado con el rendimiento académico.

Hipótesis 1: El curso de preparación influye en el rendimiento académico

Planteamiento

Se busca evaluar si los estudiantes que completaron el curso de preparación obtienen mejores resultados que quienes no lo hicieron.

Variables

- Variable independiente: test preparation course
- Variable dependiente: puntaje promedio

El puntaje promedio se calcula a partir de:

- math score
- reading score
- writing score

Hipótesis

- H0: No existen diferencias significativas entre los grupos
- H1: Sí existen diferencias significativas entre los grupos

Justificación

Esta hipótesis es importante porque permite evaluar si una estrategia concreta, como un curso de preparación, realmente tiene impacto en el rendimiento académico.

Test estadístico

- t de Student para muestras independientes
- Mann-Whitney U (como apoyo)

Resultados

- Promedio grupo completed: 72.67
- Promedio grupo none: 65.04
- Welch t-test: p-valor = 4.43e-17
- Mann-Whitney U: p-valor = 6.20e-16
- Tamaño del efecto: 0.55

Conclusión

Como el p-valor es menor a 0.05, se rechaza la hipótesis nula.
Esto indica que los estudiantes que realizaron el curso obtienen mejores resultados en promedio.

Hipótesis 2: Nivel educativo de los padres y rendimiento académico

Planteamiento

Se busca analizar si el nivel educativo de los padres influye en el desempeño de los estudiantes.

Variables

- Variable independiente: nivel educativo de los padres
- Variable dependiente: puntaje promedio

Hipótesis

- H0: No hay diferencias entre grupos
- H1: Sí hay diferencias entre grupos

Justificación

Permite entender si el contexto familiar tiene relación con el rendimiento académico y detectar posibles desigualdades.

Test estadístico

- ANOVA de una vía
- Kruskal-Wallis (apoyo)
- Levene (homogeneidad de varianzas)

Resultados

Promedios:

- high school: 63.10
- some high school: 65.11
- some college: 68.48
- associate’s degree: 69.57
- bachelor’s degree: 71.92
- master’s degree: 73.60

Resultados estadísticos:

- ANOVA: p-valor = 4.38e-10
- Levene: p-valor = 0.77
- Kruskal-Wallis: p-valor = 1.65e-08

Conclusión

Se rechaza la hipótesis nula.
Se observa que, en general, a mayor nivel educativo de los padres, mayor es el puntaje promedio de los estudiantes.

Importancia de las hipótesis

Estas hipótesis permiten analizar dos aspectos clave:

- Factores de intervención (curso de preparación)
- Factores de contexto familiar (educación de los padres)

Ambos ayudan a entender mejor qué variables están relacionadas con el rendimiento académico.

Fase 4: KPI's

A continuación, se muestran 5 KPI's de suma importancia para el análisis de los datos.

1. **Promedio general de rendimiento académico:**
   Este KPI hace referencia al promedio de los puntajes de matemáticas, lectura y escritura.
   La fórmula para calcular este KPI sería la siguiente:

$$puntaje\ promedio = \frac{puntaje\ matemáticas + puntaje\ lectura + puntaje\ escritura}{3}$$

   Se usa en varias hipótesis como variable dependiente.

   Si el resultado es alto entonces se tiene un buen desempeño, si por el contrario el resultado es bajo, entonces, es posible que el estudiante requiera intervención.

2. **Impacto del curso de preparación:**
   Hace referencia a la diferencia de promedio entre estudiantes con y sin curso.
   La fórmula para calcular este KPI sería la siguiente:

$$Impacto = promedio(completed) - promedio(none)$$

Este KPI nos permite evaluar si intervenir en un grupo tiene efecto o no, si el resultado es cercano a cero entonces no afecta tanto la intervención en un grupo. Está relacionado directamente con la hipótesis 1 en la cual se plantea que tanto afectan los cursos de preparación a los estudiantes.
Relacionado con la hipótesis 1.

3. **Rendimiento por nivel educativo de los padres:**
   Este indicador mide el rendimiento académico promedio de los estudiantes agrupado según el nivel educativo de sus padres, con el fin de identificar posibles diferencias en el desempeño asociadas al contexto familiar.

$$\text{Rendimientog} = \frac{\sum_{i=1}^{ng}\left(\frac{mat + lec + esc}{3}\right)}{ng}$$

Este KPI es relevante porque permite analizar cómo el entorno familiar, específicamente el nivel educativo de los padres, se relaciona con el desempeño académico de los estudiantes. Esto facilita la identificación de posibles brechas educativas y contribuye a la formulación de estrategias de apoyo dirigidas a poblaciones específicas.

Este indicador se encuentra directamente relacionado con la hipótesis 2, la cual evalúa si existen diferencias significativas en el rendimiento académico según el nivel educativo de los padres. El KPI permite observar y cuantificar dichas diferencias entre grupos.

- Un incremento en el rendimiento promedio a medida que aumenta el nivel educativo de los padres sugiere una relación positiva entre ambas variables.
- Diferencias marcadas entre grupos indican posibles desigualdades en el acceso a recursos o apoyo académico.
- Valores similares entre grupos indicarían que el nivel educativo de los padres no tiene una influencia significativa en el rendimiento.

4. **Brecha de rendimiento entre grupos (género / almuerzo / grupo étnico)**
   Este indicador mide la diferencia en el rendimiento académico promedio entre distintos grupos de estudiantes, como género, tipo de almuerzo o grupo étnico, con el fin de identificar posibles desigualdades en el desempeño.

$$Brecha = promedio\ grupo\ A - promedio\ grupo\ B$$

Este KPI es relevante desde una perspectiva educativa, ya que permite detectar diferencias significativas entre grupos poblacionales. La identificación de estas brechas es clave para diseñar estrategias de intervención orientadas a reducir desigualdades y mejorar el rendimiento académico en poblaciones específicas.

Este indicador se relaciona con la tercera pregunta de análisis planteada en la Fase 1, la cual busca determinar si existen diferencias en el rendimiento académico entre grupos de estudiantes según variables demográficas y de contexto.

- Una brecha alta indica desigualdad significativa entre grupos.
- Una brecha cercana a cero sugiere un comportamiento homogéneo.
- Una brecha negativa indica que el grupo comparado presenta mejor rendimiento.

5. **Porcentaje de estudiantes con bajo rendimiento**
Este indicador mide el porcentaje de estudiantes cuyo rendimiento académico promedio se encuentra por debajo de un umbral definido, permitiendo identificar la proporción de estudiantes en riesgo académico.

$$Porcentaje\ bajo\ rendimiento = \frac{número\ de\ estudiantes\ con\ promedio < umbral}{Total\ estudiantes}$$

Este KPI es fundamental para la toma de decisiones en el ámbito educativo, ya que permite identificar la magnitud del problema de bajo rendimiento dentro de la población estudiantil. A partir de este indicador, se pueden diseñar estrategias de apoyo académico focalizadas.

Este indicador complementa las hipótesis planteadas , ya que permite analizar cómo factores como el curso de preparación y el nivel educativo de los padres influyen en la proporción de estudiantes con bajo desempeño.

- Un porcentaje alto indica una mayor proporción de estudiantes en riesgo académico.
- Un porcentaje bajo sugiere un buen desempeño general del grupo.
- Permite evaluar el impacto de estrategias educativas en la reducción del bajo rendimiento.

Conclusiones

A partir del análisis realizado, se puede concluir que el rendimiento académico de los estudiantes no depende de un solo factor, sino de una combinación de variables tanto académicas como de contexto.

En primer lugar, se encontró que el curso de preparación para exámenes tiene una relación clara con el desempeño académico. Los estudiantes que completaron este curso obtuvieron, en promedio, mejores puntajes que aquellos que no lo hicieron. Esto sugiere que este tipo de estrategias de apoyo pueden tener un impacto positivo y podrían ser reforzadas por las instituciones educativas.

Por otro lado, el nivel educativo de los padres también mostró una relación significativa con el rendimiento de los estudiantes. En general, se observó que a medida que aumenta el nivel educativo de los padres, también tiende a mejorar el desempeño académico. Esto indica que el entorno familiar puede influir en los resultados, posiblemente debido a factores como el apoyo en el estudio o el acceso a recursos.

Además, el análisis de los KPI's permitió identificar patrones importantes, como diferencias de rendimiento entre grupos de estudiantes y la existencia de una proporción de alumnos en riesgo académico. Estos indicadores son útiles para tener una visión más clara de la situación y facilitar la toma de decisiones.

En conjunto, los resultados del análisis permiten entender mejor qué factores están asociados al rendimiento académico y ofrecen una base para proponer acciones orientadas a mejorar el desempeño estudiantil. Entre estas acciones se podrían considerar el fortalecimiento de programas de preparación académica y el diseño de estrategias de apoyo más focalizadas en los grupos que presentan mayores dificultades.